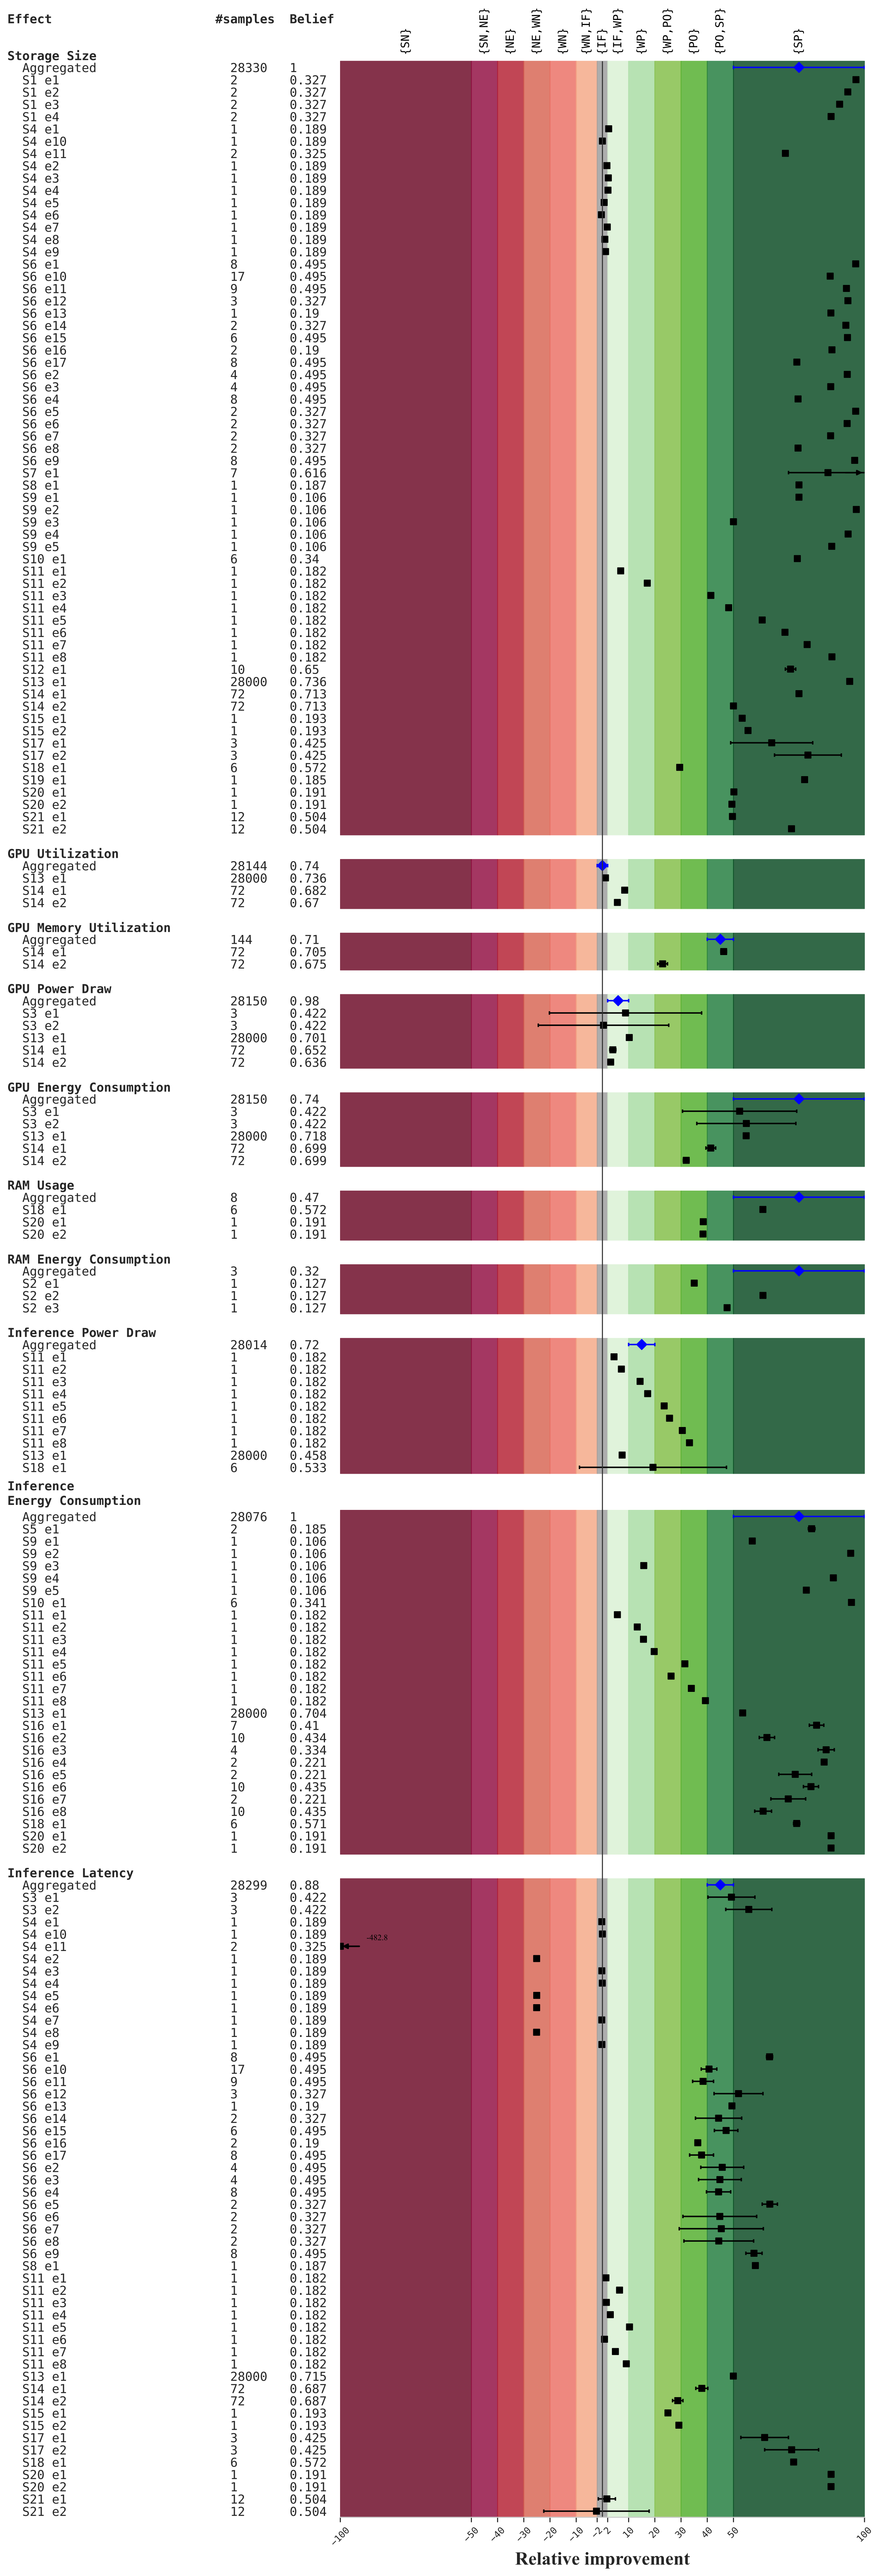
Effect
#samples
Belief
{SN}
{SN,NE}
{NE}
{NE,WN}
{WN}
{WN,IF}
{IF}
{IF,WP}
{WP}
{WP,PO}
{PO}
{PO,SP}
{SP}
Storage Size
Aggregated 28330 1
S1 e1 2 0.327
S1 e2 2 0.327
S1 e3 2 0.327
S1 e4 2 0.327
S4 e1 1 0.189
S4 e10 1 0.189
S4 e11 2 0.325
S4 e2 1 0.189
S4 e3 1 0.189
S4 e4 1 0.189
S4 e5 1 0.189
S4 e6 1 0.189
S4 e7 1 0.189
S4 e8 1 0.189
S4 e9 1 0.189
S6 e1 8 0.495
S6 e10 17 0.495
S6 e11 9 0.495
S6 e12 3 0.327
S6 e13 1 0.19
S6 e14 2 0.327
S6 e15 6 0.495
S6 e16 2 0.19
S6 e17 8 0.495
S6 e2 4 0.495
S6 e3 4 0.495
S6 e4 8 0.495
S6 e5 2 0.327
S6 e6 2 0.327
S6 e7 2 0.327
S6 e8 2 0.327
S6 e9 8 0.495
S7 e1 7 0.616
S8 e1 1 0.187
S9 e1 1 0.106
S9 e2 1 0.106
S9 e3 1 0.106
S9 e4 1 0.106
S9 e5 1 0.106
S10 e1 6 0.34
S11 e1 1 0.182
S11 e2 1 0.182
S11 e3 1 0.182
S11 e4 1 0.182
S11 e5 1 0.182
S11 e6 1 0.182
S11 e7 1 0.182
S11 e8 1 0.182
S12 e1 10 0.65
S13 e1 28000 0.736
S14 e1 72 0.713
S14 e2 72 0.713
S15 e1 1 0.193
S15 e2 1 0.193
S17 e1 3 0.425
S17 e2 3 0.425
S18 e1 6 0.572
S19 e1 1 0.185
S20 e1 1 0.191
S20 e2 1 0.191
S21 e1 12 0.504
S21 e2 12 0.504
GPU Utilization
Aggregated 28144 0.74
S13 e1 28000 0.736
S14 e1 72 0.682
S14 e2 72 0.67
GPU Memory Utilization
Aggregated 144 0.71
S14 e1 72 0.705
S14 e2 72 0.675
GPU Power Draw
Aggregated 28150 0.98
S3 e1 3 0.422
S3 e2 3 0.422
S13 e1 28000 0.701
S14 e1 72 0.652
S14 e2 72 0.636
GPU Energy Consumption
Aggregated 28150 0.74
S3 e1 3 0.422
S3 e2 3 0.422
S13 e1 28000 0.718
S14 e1 72 0.699
S14 e2 72 0.699
RAM Usage
Aggregated 8 0.47
S18 e1 6 0.572
S20 e1 1 0.191
S20 e2 1 0.191
RAM Energy Consumption
Aggregated 3 0.32
S2 e1 1 0.127
S2 e2 1 0.127
S2 e3 1 0.127
Inference Power Draw
Aggregated 28014 0.72
S11 e1 1 0.182
S11 e2 1 0.182
S11 e3 1 0.182
S11 e4 1 0.182
S11 e5 1 0.182
S11 e6 1 0.182
S11 e7 1 0.182
S11 e8 1 0.182
S13 e1 28000 0.458
S18 e1 6 0.533
Inference
Energy Consumption
Aggregated 28076 1
S5 e1 2 0.185
S9 e1 1 0.106
S9 e2 1 0.106
S9 e3 1 0.106
S9 e4 1 0.106
S9 e5 1 0.106
S10 e1 6 0.341
S11 e1 1 0.182
S11 e2 1 0.182
S11 e3 1 0.182
S11 e4 1 0.182
S11 e5 1 0.182
S11 e6 1 0.182
S11 e7 1 0.182
S11 e8 1 0.182
S13 e1 28000 0.704
S16 e1 7 0.41
S16 e2 10 0.434
S16 e3 4 0.334
S16 e4 2 0.221
S16 e5 2 0.221
S16 e6 10 0.435
S16 e7 2 0.221
S16 e8 10 0.435
S18 e1 6 0.571
S20 e1 1 0.191
S20 e2 1 0.191
Inference Latency
Aggregated 28299 0.88
S3 e1 3 0.422
S3 e2 3 0.422
S4 e1 1 0.189
S4 e10 1 0.189
S4 e11 2 0.325
S4 e2 1 0.189
S4 e3 1 0.189
S4 e4 1 0.189
S4 e5 1 0.189
S4 e6 1 0.189
S4 e7 1 0.189
S4 e8 1 0.189
S4 e9 1 0.189
S6 e1 8 0.495
S6 e10 17 0.495
S6 e11 9 0.495
S6 e12 3 0.327
S6 e13 1 0.19
S6 e14 2 0.327
S6 e15 6 0.495
S6 e16 2 0.19
S6 e17 8 0.495
S6 e2 4 0.495
S6 e3 4 0.495
S6 e4 8 0.495
S6 e5 2 0.327
S6 e6 2 0.327
S6 e7 2 0.327
S6 e8 2 0.327
S6 e9 8 0.495
S8 e1 1 0.187
S11 e1 1 0.182
S11 e2 1 0.182
S11 e3 1 0.182
S11 e4 1 0.182
S11 e5 1 0.182
S11 e6 1 0.182
S11 e7 1 0.182
S11 e8 1 0.182
S13 e1 28000 0.715
S14 e1 72 0.687
S14 e2 72 0.687
S15 e1 1 0.193
S15 e2 1 0.193
S17 e1 3 0.425
S17 e2 3 0.425
S18 e1 6 0.572
S20 e1 1 0.191
S20 e2 1 0.191
S21 e1 12 0.504
S21 e2 12 0.504
-482.8
−100
−50
−40
−30
−20
−10
−2
2
10
20
30
40
50
100
Relative improvement