

The figure displays the relative improvement of various models across different metrics. The metrics are grouped into categories: Storage Size, GPU Utilization, GPU Power Draw, GPU Energy Consumption, RAM Usage, Inference Power Draw, and Inference Energy Consumption. The models are represented by different colors in the heatmap and dot plots.

Metric	n_{eff}	Belief
Storage Size		
S1 e1	2	0.327
S1 e2	2	0.327
S1 e3	2	0.327
S1 e4	2	0.327
S4 e1	1	0.189
S4 e2	1	0.189
S4 e3	1	0.189
S4 e4	1	0.189
S4 e5	1	0.189
S4 e6	1	0.189
S4 e7	1	0.189
S4 e8	1	0.189
S4 e9	1	0.189
S4 e10	1	0.189
S4 e11	2	0.325
S6 e1	2	0.327
S6 e2	2	0.327
S6 e3	2	0.327
S6 e4	2	0.327
S6 e5	2	0.327
S6 e6	2	0.327
S6 e7	2	0.327
S6 e8	2	0.327
S6 e9	2	0.327
S6 e10	1	0.19
S6 e11	1	0.19
S6 e12	2	0.327
S6 e13	2	0.327
S6 e14	2	0.327
S6 e15	2	0.327
S6 e16	2	0.327
S6 e17	2	0.327
S7 e1	4	0.502
S8 e1	1	0.187
S9 e1	1	0.106
S9 e2	1	0.106
S9 e3	1	0.106
S9 e4	1	0.106
S9 e5	1	0.106
S10 e1	6	0.34
S11 e1	1	0.186
S11 e2	1	0.186
S11 e3	1	0.186
S11 e4	1	0.186
S11 e5	1	0.186
S11 e6	1	0.186
S11 e7	1	0.186
S11 e8	1	0.186
S12 e1	9	0.641
S13 e1	28	0.722
S14 e1	18	0.712
S14 e2	18	0.712
S15 e1	1	0.193
S15 e2	1	0.193
S17 e1	3	0.425
S17 e2	3	0.425
S18 e1	6	0.572
S19 e1	1	0.185
S20 e1	1	0.191
S20 e2	1	0.191
S21 e1	4	0.504
S21 e2	4	0.504
Aggregated	1	1
GPU Utilization		
S13 e1	28	0.668
S14 e1	18	0.681
S14 e2	18	0.669
Aggregated	18	0.968
GPU Power Draw		
S3 e1	3	0.422
S3 e2	3	0.422
S13 e1	28	0.707
S14 e1	18	0.651
S14 e2	18	0.635
Aggregated	18	0.984
GPU Energy Consumption		
S3 e1	3	0.422
S3 e2	3	0.422
S13 e1	28	0.719
S14 e1	18	0.697
S14 e2	18	0.697
Aggregated	18	0.742
RAM Usage		
S18 e1	6	0.572
S20 e1	1	0.191
S20 e2	1	0.191
Aggregated	1	0.467
Inference Power Draw		
S11 e1	1	0.186
S11 e2	1	0.186
S11 e3	1	0.186
S11 e4	1	0.186
S11 e5	1	0.186
S11 e6	1	0.186
S11 e7	1	0.186
S11 e8	1	0.186
S13 e1	28	0.675
S18 e1	6	0.524
Aggregated	6	0.742
Inference Energy Consumption		
S5 e1	2	0.185
S9 e1	1	0.106
S9 e2	1	0.106
S9 e3	1	0.106
S9 e4	1	0.106
S9 e5	1	0.106
S10 e1	6	0.341
S11 e1	1	0.186
S11 e2	1	0.186
S11 e3	1	0.186
S11 e4	1	0.186
S11 e5	1	0.186
S11 e6	1	0.186